

**Akademia Górniczo-Hutnicza
im. Stanisława Staszica w Krakowie**

Wydział Informatyki, Elektroniki i Telekomunikacji

KATEDRA INFORMATYKI



PRACA MAGISTERSKA

MARTA RYŁKO, ANNA SKIBA

**RÓWNOLEGŁE ALGORYTMY OPTIMALIZACJI TORU
PRZEJAZDU W NARCIARSTWIE ALPEJSKIM**

PROMOTOR:
dr inż. Roman Dębski

Kraków 2013

OŚWIADCZENIE AUTORA PRACY

OŚWIADCZAM, ŚWIADOMY ODPOWIEDZIALNOŚCI KARNEJ ZA POŚWIADCZENIE NIEPRAWDY, ŻE NINIEJSZĄ PRACĘ DYPLOMOWĄ WYKONAŁEM OSOBIŚCIE I SAMODZIELNIE, I NIE KORZYSTAŁEM ZE ŹRÓDEŁ INNYCH NIŻ WYMIENIONE W PRACY.

.....

PODPIS

AGH
University of Science and Technology in Krakow

Faculty of Computer Science, Electronics and Telecommunication

DEPARTMENT OF COMPUTER SCIENCE



MASTER OF SCIENCE THESIS

MARTA RYŁKO, ANNA SKIBA

**PARALLEL ALGORITHMS FOR SKI-LINE OPTIMISATION IN
ALPINE SKI RACING**

SUPERVISOR:
Roman Dębski Ph.D

Krakow 2013

Serdecznie dziękuję ...

Spis treści

1. Wstęp	6
1.1. Cele pracy	7
1.2. Zawartość pracy	7
2. Wprowadzenie teoretyczne	8
2.1. Fizyczny model narciarza	8
2.2. Metody numeryczne rozwiązywania równań różniczkowych	8
2.3. Optymalizacja	8
2.3.1. Algorytm ewolucyjny	8
2.3.2. Hill up climbing	12
2.4. Uczenie maszynowe	12
3. Istniejące rozwiązania	13
3.1. Rozwiązanie 1	13
4. Proponowane rozwiązanie	14
4.1. Model narciarza i środowiska	14
4.2. Opis matematyczny modelu	14
4.3. Numeryczne rozwiązanie problemu	15
4.3.1. Rozwiązanie w 3D	16
4.4. Optymalizacja toru przejazdu	17
4.4.1. Algorytm ewolucyjny	17
4.5. Architektura systemu	17
5. Wyniki	18
5.1. Optymalizacja	18
5.1.1. Algorytm ewolucyjny	18
5.1.2. Lokalna optymalizacja	18
5.2. Uczenie maszynowe	18
5.3. Podsumowanie	18
5.4. Optymalizacja toru przejazdu	18
5.5. Architektura systemu	18
6. Podsumowanie	19
6.1. Podrozdział	19

1. Wstęp

Narciarstwo alpejskie to dyscyplina z długą historią. Rozwój sportowej wersji narciarstwa alpejskiego rozpoczął się w połowie XIX wieku, jednak nadal nie ma i prawdopodobnie nigdy nie będzie naukowej formuły opisującej tor po jakim należy się poruszać, aby zadaną trasę przejechać najszybciej. Ogromna ilość czynników, które wpływają na czas przejazdu znacznie utrudnia jej znalezienie. W sportowych dyscyplinach narciarstwa alpejskiego celem jest przejechanie w jak najkrótszym czasie wyznaczonej trasy od startu do mety, przejeżdżając przez wszystkie ustawione na trasie bramki - wymuszające skęty.

Problem, jakiego rozwiązania podejmujemy się w pracy, to problem optymalizacyjny rozwiązywany za pomocą symulacji komputerowej. Problem dotyczy znalezienia optymalnego toru przejazdu narciarza po trasie slalomu, który nakłada ograniczenia na ten tor w postaci bramek. Każda bramka ściśle narzuca, z której strony należy ją przejechać, a ominięcie chociaż jednej z nich powoduje dyskwalifikację zawodnika.

Zdefiniowany przez nas problem jest interdyscyplinarny - z pogranicza fizyki i informatyki. Do dobrego zrozumienia zjawisk zachodzących na stoku narciarskim cenne jest też posiadanie własnych doświadczeń z jazdy po trasach slalomu. Wymagania te powodują, że problem nie jest trywialny do rozwiązania i w celu badania go nieodłączne są osoby o różnych kompetencjach.

Obecnie nie udało nam się znaleźć publicznie dostępnych prac, które podchodziłyby do rozwiązania tego praktycznego problemu. Zdajemy sobie sprawę, że problem jest bardzo złożony i próby jego rozwiązania to tak naprawdę rozwiązanie uproszczone tego problemu. Dodatkowo, uwzględnić trzeba fakt, że wiele zmiennych występujących w równaniach wpływa na siebie nawzajem, powodując zmiany niekoniecznie widoczne natychmiast. Może to na przykład sprawiać, że niewielka zmiana dokonana na początku jazdy może mieć znaczący wpływ na ostateczny wynik, co znacznie utrudnia wszelką predykcję na temat wpływu zmian. Aby rozwiązać problem, stworzyliśmy fizyczny model narciarza - zamodelowany jako punkt materialny o konfigurowalnych parametrach, co umożliwia porównanie wyników np. dla zawodników o różnych masach. Potraktowanie narciarza jako punktu materialnego jest pierwszym z zastosowanych uproszczeń, które zdecydowałyśmy się przyjąć w naszym rozwiązaniu. Stok modelowany jest jako płaszczyzna o zadanym kącie nachylenia, na której za pomocą współrzędnych oznaczamy miejsce występowania bramek. Dużym wyzwaniem było dobranie przybliżenia trasy przejazdu, aby umożliwić wystarczająco łatwe obliczenia i jednocześnie nie tracąc zbyt wiele na dokładności oddania realnej trasy. Łamana, którą wybrałyśmy jako rozwiązanie spełniające obydwa te wymagania, jest wystarczająco dobrym przybliżeniem jeśli narzucimy na nią dodatkowe ograniczenia jak eliminacja ostrych kątów załamania.

Kluczową częścią naszego rozwiązania jest wykorzystanie algorytmu genetycznego do wybrania pewnego lokalnego optimum trasy, a następnie przeprowadzamy lokalną optymalizację celem wygładzenia znalezionej trasy. Aby przyspieszyć obliczenia, zastosowałyśmy architekturę opartą o rozproszonych klientów wykonujących obliczenia i raportujących do głównego serwera. Na podstawie zebranych danych od klientów, serwer jest w stanie dostarczyć rozwiązanie szybciej oraz można mieć większą pewność, iż jest ono jeśli nie optymalne, to bardzo bliskie optymalnego. Obliczenia wykonywane są w środowisku przeglądarek internetowych w języku JavaScript.

Otrzymane rozwiązanie może mieć zastosowanie nie tylko w celu znajdowania optymalnej trasy przejazdu po zadanym slalomie. Przykładem może być wsparcie dla trenerów ustawiających takie slalomy w postaci aplikacji podpowiadającej gdzie ustawić kolejną bramkę, aby nie było problemów z jej przejechaniem. Dodatkowo, dokładając moduł wyliczający naprężenia i siły działające na stawy kolanowe, można by zredukować negatywny wpływ niefortunnie ustawionych bramek, powodujących wyjątkowe przeciążenia w kolanach, wykrywając to i przedstawiając bramki.

1.1. Cele pracy

Celem poniższej pracy jest zapoznanie studentów z systemem \LaTeX w zakresie umożliwiającym im samodzielne, profesjonalne złożenie pracy dyplomowej w systemie \LaTeX .

1.2. Zawartość pracy

W rozdziale ?? przedstawiono podstawowe informacje dotyczące struktury dokumentów w \LaTeX u. *Alvis* [3] jest językiem

2. Wprowadzenie teoretyczne

W rozdziale tym przedstawiono informacje .

2.1. Fizyczny model narciarza

2.2. Metody numeryczne rozwiązywania równań różniczkowych

2.3. Optymalizacja

W tym podrozdziale opisane są metody optymalizacji użyte w zaproponowanym rozwiązaniu, czyli algorytm ewolucyjny oraz algorytm optymalizacji lokalnej - Hill up climbing.

Zadaniem optymalizacji jest przeszukanie przestrzeni rozwiązań w celu znalezienia takiego, które jest najlepsze. Zatem mając daną funkcję nazywaną funkcją celu, która każdemu punktowi reprezentującemu rozwiązanie problemu, poszukujemy takiego, dla którego wartość tej funkcji będzie jak najmniejsza (bądź jak największa). Trudność w znalezieniu takiego rozwiązania zależy od charakteru funkcji celu, a czasem także od nieznajomości jej analitycznej postaci.

Optymalizacja lokalna i globalna

W przypadku funkcji z jednym optimum

Jeśli natomiast funkcja celu posiada wiele optimumów lokalnych (tzw. funkcja wielomodalna) to optymalizację nazywamy optymalizacją globalną. Jeśli zadanie jest ciągłe, a więc niemożliwe jest przeszukanie całej przestrzeni rozwiązań, nigdy nie możemy być pewni, że zastosowany algorytm optymalizacji da nam rozwiązanie najlepsze - być może będzie to tylko minimum lokalne a nie globalne. Nie mając takiej pewności nie wiemy kiedy należy zatrzymać algorytm. Z tego powodu stosuje się parametr sterujący czasem trwania obliczeń, kosztem mniejszej pewności co do poprawności rozwiązania możemy otrzymać krótszy czas optymalizacji i odwrotnie.

2.3.1. Algorytm ewolucyjny

Algorytm ewolucyjny jest przykładem algorytmu optymalizacyjnego, przeszukającego przestrzeń rozwiązań w celu znalezienia najlepszego rozwiązania problemu. Algorytm ten oparty jest na obserwacjach środowiska i przystosowywania się organizmów do jego warunków. Wiele terminów zapożyczonych jest zatem z genetyki.

Podstawą całego algorytmu jest populacja osobników, z których każdy reprezentuje rozwiązanie problemu. Populacja ta zmienia się wraz z działaniem algorytmu. Ewolucja zakłada, że populacja będzie się składać z coraz lepiej przystosowanych osobników. Przystosowanie to jest obliczane za pomocą wcześniej określonej funkcji oceniającej jakość danego osobnika, czyli jak dobre jest rozwiązanie reprezentowane przez niego. Przystosowanie jest wartością liczbową obliczoną za pomocą tej funkcji przystosowania.

Funkcja przystosowania określa wartość przystosowania osobnika na podstawie jego fenotypu, który jest tworzony z genotypu. Genotyp określa zestaw cech danego osobnika i składa się z chromosomów (najczęściej z jednego). Natomiast każdy z chromosomów składa się z elementarnych jednostek - genów.

Schemat działa algorytmu ewolucyjnego

Algorytm ewolucyjny rozpoczyna się poprzez wygenerowanie populacji bazowej oraz obliczenie przystosowania jej osobników. Przeważnie osobniki te generowane są całkowicie losowo, ale można także wprowadzić konkretne osobniki np. o znanym dobrym przystosowaniu do środowiska.

Główna część algorytmu opiera się na powtarzaniu pętli, w której wykonywane są kolejno:

- reprodukcja
- operacje genetyczne
- ocena
- sukcesja

Często reprodukcję i sukcesję łączy się pod nazwą selekcja.

Reprodukcja powoduje powielenie losowo wybranych osobników z populacji. Prawdopodobieństwo wybrania osobnika do powielenia najczęściej jest proporcjonalne do jego przystosowania. Może się zdarzyć, że dany osobnik zostanie wybrany więcej niż raz, a także, że nie zostanie wybrany ani razu.

Następnie na tych kopiach przeprowadzane są operacje genetyczne powodujące zmiany w genotypie osobników. Wyróżniamy dwie podstawowe operacje:

- mutacja
- krzyżowanie

Zadaniem mutacji jest losowe zmodyfikowanie genów w genotypie.

Krzyżowanie, zwane także rekombinacją (ang. *crossover*), działa na conajmniej dwóch osobnikach i na podstawie ich genotypu tworzy jeden lub więcej osobników potomnych. Chromosomy rodzicielskie są mieszane w celu otrzymania nowych genotypów dla osobników potomnych.

W wyniku operacji genetycznych powstają nowe osobniki, które wchodzi w skład populacji potomnej. Każdy z tych osobników jest oceniany za pomocą funkcji przystosowania. Porównując jakość osobników z populacji bazowej oraz potomnej dokonuje się sukcesji, czyli wyboru osobników z tych populacji (czasem wyłącznie z populacji potomnej) i tworzy nową populację bazową.

Zakończenie działania algorytmu przeważnie opiera się na badaniu funkcji przystosowania całej populacji. Jeśli wartość przystosowania populacji nie jest zróżnicowana mówimy o stagnacji algorytmu i może być to wskazaniem do zakończenia działania algorytmu. Czasem jednak oczekuje się aż przystosowanie to będzie wystarczająco duże, żeby stwierdzić, że znalezione rozwiązanie jest bardzo dobre. Przeważnie jednak nie znamy nawet przybliżonej wartości jakości rozwiązania, więc nie możemy stwierdzić kiedy przystosowanie jest odpowiednie i czy nie może się jeszcze znacznie poprawić.

Kodowanie osobników

W przypadku algorytmów genetycznych, będących szczególnym przypadkiem algorytmów ewolucyjnych, do kodowania osobników stosuje się kodowanie binarne chromosomów. Pojedynczy bit reprezentuje zatem gen należący do chromosomu.

W takim przypadku mutacja wykonywana jest na każdym genie osobno z pewnym prawdopodobieństwem, jeśli do niej dochodzi, zmienia się wartość bitu na przeciwną. W krzyżowaniu wybiera się dwa osobniki rodzicielskie, których chromosomy rozcinane są na dwie części i łączone łańcuchem krzyż. Miejsce przecięcia jest losowane z rozkładem równomiernym.

W algorytmach ewolucyjnych porzuca się kodowanie binarne - chromosom składa się z jednej lub więcej liczb stanowiących cechy osobnika.

Mutacja takiego osobnika najczęściej odbywa się poprzez losową zmianę każdej z wartości genów chromosomu. Do krzyżowania wybiera się dwa osobniki, z których dla każdej pary odpowiadających genów wyciągana jest średnia i tak otrzymane wartości genów tworzą genotyp nowego osobnika.

Typy algorytmów ewolucyjnych

Algorytmy ewolucyjne wywodzą się z kilku osobnych nurtów zajmujących się tą tematyką, więc istnieje wiele podobnych schematów. Najlepiej traktować algorytmy ewolucyjne jako metaheurystykę - określony jest pewien szkic algorytmu, który można dostosowywać do konkretnego rozwiązania. W tym podrozdziale opisane są podstawowe i najbardziej popularne schematy postępowania oparte o algorytmy ewolucyjne.

Prosty algorytm genetyczny Prosty algorytm genetyczny został zaproponowany w roku 1975 przez John'a Holland'a.

Mając populację bazową P^t dokonujemy reprodukcji tej populacji, tworząc populację tymczasową T^t składającą się z takiej samej liczby osobników. Wybierani są oni z prawdopodobieństwem proporcjonalnym do ich przystosowania z populacji bazowej. Na populacji tymczasowej dokonujemy operacji genetycznych (mutacji i krzyżowania). Do krzyżowania wybierane są rozłączne pary osobników i z pewnym prawdopodobieństwem p_c zachodzi ich skrzyżowanie. Jeśli doszło do powstania osobników potomnych zastępują one osobniki rodzicielskie. Następnie na tak otrzymanej populacji tymczasowej dochodzi do mutacji osobników i otrzymania populacji potomnej O^t . Ta populacja staje się w następnej iteracji algorytmu nową populacją bazową.

Zatrzymanie algorytmu może być dokonane jeśli np.:

- wykonano określoną z góry liczbę iteracji
- znaleziono osobnika o wystarczająco wysokiej wartości przystosowania

W tej wersji algorytmu często pętlę algorytmu nazywa się generacją, a każdą populację P^t w chwili t pokoleniem.

Strategia (1+1) Strategia (1+1) jest podstawową strategii ewolucyjnych. W algorytmie tym mamy doczynienia z populacją składającą się z tylko jednego osobnika posiadającego jeden chromosom. W każdej pętli algorytmu dokonuje się mutacji tego chromosomu, co powoduje powstanie nowego osobnika. Osobnik ten jest poddawany ocenie, a następnie dokonuje się wyboru lepszego z dwóch istniejących osobników i tego pozostawia w populacji. W mutacji dodaje się do każdego genu chromosomu losową modyfikację rozkładem normalnym:

$$Y_i^t = X_i^t + \sigma \xi_{N(0,1),i} \quad (2.1)$$

Wartość σ będzie powodowała większe lub mniejsze zmiany w chromosomie. Jeśli chcemy przeszukać przestrzeń, powinniśmy zwiększać jej wartość, co jest pożądane zwłaszcza w początkowej fazie działania algorytmu. Natomiast, aby znaleźć jak najlepsze rozwiązanie, wiedząc że obecne rozwiązanie jest już bardzo bliskie najlepszemu, możemy zmniejszać wartość σ przeszukując tylko najbliższą przestrzeń.

Do wyznaczania σ powstał następujący algorytm zwany regułą 1/5 sukcesów:

1. Jeśli przez kolejnych k pętli algorytmu mutacja powoduje powstanie lepszego osobnika w więcej niż $1/5$ wszystkich mutacji, to zwiększamy σ : $\sigma' = c_i \sigma$. Wartość c_i wyznaczona empirycznie wynosi $\frac{1}{0.82}$
2. Gdy dokładnie $1/5$ kończy się sukcesem, wartość σ pozostaje bez zmian.
3. Jeśli nie zachodzi żadne z powyższych wartość σ jest zmniejszana: $\sigma' = c_d \sigma$. Gdzie c_d powinna wynosić 0.82

Strategia $(\mu + \lambda)$ Strategia $(\mu + \lambda)$ jest rozwinięciem strategii $(1+1)$. μ oznacza ilość osobników w populacji początkowej, a λ ile osobników jest reprodukowanych i poddawanych operacjom genetycznym. Dodatkowo, zamiast reguły $1/5$ sukcesów wprowadzono mechanizm samoczynnej adaptacji zasięgu mutacji, a także wprowadzono operator krzyżowania.

Oznaczenie $\mu + \lambda$ oznacza, że po wygenerowaniu populacji potomnej wybierane jest μ najlepszych osobników do nowej populacji bazowej - zarówno spośród populacji potomnej, jak i starej populacji bazowej zawierającej łącznie $\mu + \lambda$ osobników.

W strategii tej ważne jest też kodowanie, do którego dodatkowo dołożono również chromosom przechowujący wektor σ zawierający wartości odchyłeń standardowych, które wykorzystuje się w trakcie mutacji.

Po wylosowaniu wartości zmiennej losowej o rozkładzie normalnym $(\xi_{N(0,1)})$ dla każdego elementu wektora σ losujemy jeszcze jedną zmienną losową o rozkładzie normalnym $(\xi_{N(0,1),i})$ i oblicza nowe wartości odchyłeń z wektora σ :

$$\sigma'_i = \sigma_i e^{(\tau' \xi_{N(0,1)} + \tau \xi_{N(0,1),i})} \quad (2.2)$$

Gdzie τ oraz τ' są parametrami algorytmu, a ich wartości powinny wynosić:

$$\tau = \frac{K}{\sqrt{2n}} \quad (2.3)$$

$$\tau' = \frac{K}{\sqrt{2}\sqrt{n}} \quad (2.4)$$

Mając dane nowe wartości odchyłeń standardowych możemy obliczyć nowe wartości genów korzystając ze wzoru:

$$X'_i = X_i + \sigma'_i \xi_{N(0,1),i} \quad (2.5)$$

gdzie $\xi_{N(0,1),i}$ jest nową losową wartością.

Algorytm ewolucyjny wybiera osobniki lepiej przystosowane, a więc te, które posiadają także lepsze wartości odchyłeń standardowych. Powoduje to naturalną selekcję, doprowadzającą do samoczynnej adaptacji odchyłeń standardowych stosowanych w trakcie mutacji.

Krzyżowanie występuje w tym algorytmie pod nazwą rekombinacja. Najczęściej sprowadza się do uśrednienia lub wymianie wartości wektorów, także wektora σ .

Strategia (μ, λ) Strategia $(\mu + \lambda)$ posiada pewne wady, które postanowiono spróbować wyeliminować za pomocą nowej strategii (μ, λ) . Poprzedni algorytm sprawia problemy jeśli w populacji pojawia się osobnik o wysokiej wartości przystosowania, ale posiadający zbyt duże (albo zbyt małe) wartości odchyłeń standardowych. Usunięcie takiego osobnika z populacji często nie jest procesem krótkotrwałym, gdyż wpływa on na powstające potomstwo, przekazując mu podobne do jego, nieodpowiednie wartości odchyłeń.

W nowej strategii wprowadzono zmianę, która powoduje, że osobniki rodzicielskie nie są nigdy brane do kolejnej populacji bazowej. Podczas selekcji korzysta się zatem tylko z powstałej populacji potomnej, z niej wybierając osobniki do populacji bazowej w kolejnej iteracji.

2.3.2. Hill up climbing**2.4. Uczenie maszynowe**

3. Istniejące rozwiązania

W rozdziale tym przedstawiono informacje .

3.1. Rozwiązanie 1

4. Proponowane rozwiązanie

W rozdziale tym przedstawiono informacje .

4.1. Model narciarza i środowiska

W zaproponowanym rozwiązaniu trzeba była podjąć pewne decyzje odnośnie reprezentacji środowiska oraz narciarza. Zostało przyjęte, że stok traktowany jest jako płaszczyzna, która jest nachylona pod określonym przez stałą α kątem do powierzchni ziemi. Założenie co do płaskiej powierzchni jest tylko ograniczeniem przyjętym do testów. Umożliwia to łatwiejszą analizę wyników niezaburzonych zmianami nachylenia terenu. Jednak stworzony program może zostać zmodyfikowany tak, aby zamodelować bardziej skomplikowaną powierzchnię. Narciarz traktowany jest jako punkt materialny o masie m .

4.2. Opis matematyczny modelu

m - masa

g - współczynnik grawitacji

α - kąt nachylenia powierzchni stoku do powierzchni ziemi

Siła grawitacji działająca na obiekt o masie m :

$$Q = mg \quad (4.1)$$

Siła ta może zostać rozłożona na dwie siły składowe względem powierzchni stoku. Narciarz poruszający się w dół stoku przypomina klasyczny przykład punktu materialnego staczającego się po równi pochyłej. Składowa siły grawitacji równoległa do powierzchni stoku:

$$Q_a = mg \sin \alpha \quad (4.2)$$

jest to siła ściąająca narciarza w dół stoku.

Składowa siły grawitacji prostopadła do powierzchni stoku:

$$F_n = mg \cos \alpha \quad (4.3)$$

Wartość tej siły wpływa na wartość siły tarcia działającej na narciarza:

$$F_f = \mu F_n = \mu mg \cos \alpha \quad (4.4)$$

Oprócz siły tarcia uwzględniamy również inną siłę oporu jaką jest siła oporu powietrza. Zależy ona od prędkości poruszania się obiektu. Prędkość będziemy wyrażać jako pierwszą pochodną położenia - \dot{x} :

$$F_d = k_1 \dot{x} + k_2 \dot{x}^2 \quad (4.5)$$

Założenia, które narzucane są na stałe k_1 oraz k_2 :

$$\begin{cases} k_2 = 0 & v \leq B \\ k_1 = 0 & v \geq B \end{cases} \quad (4.6)$$

gdzie B :

$$B = 4 \frac{m}{s} \quad (4.7)$$

Ograniczenie to zostało zaczerpnięte z pracy [1] (Aerodynamic-Drag) i opisane w rozdziale [1]

Współczynnik k_1

$$k_1 = ... \quad (4.8)$$

Współczynnik k_2 został opisany w [1]

$$k_2 = \frac{1}{2} C \rho A \quad (4.9)$$

gdzie:

C - współczynnik oporu

ρ - gęstość powietrza

A - powierzchnia przednia narciarza prostopadła do kierunku przepływu, a zatem prostopadła do wektora prędkości narciarza

4.3. Numeryczne rozwiązanie problemu

Rozpatrując wszystkie siły działające na narciarza równoległe do powierzchni stoku, a więc powodujące jego ruch w dół, otrzymujemy następujące równanie:

$$ma = mgsin\alpha - \mu mgcos\alpha - k_1 \dot{x} - k_2 \dot{x}^2 \quad (4.10)$$

Wyrażmy teraz przyspieszenie jako drugą pochodną położenia:

$$a = \ddot{x} \quad (4.11)$$

Podstawiając do równania:

$$m\ddot{x} = mgsin\alpha - \mu mgcos\alpha - k_1 \dot{x} - k_2 \dot{x}^2 \quad (4.12)$$

Zatem po podzieleniu przez m :

$$\ddot{x} = gsin\alpha - \mu gcos\alpha - \frac{k_1}{m} \dot{x} - \frac{k_2}{m} \dot{x}^2 \quad (4.13)$$

Aby rozwiązać to równanie numerycznie, wprowadzamy nową zmienną v (odpowiadającą prędkości):

$$v = \dot{x} \quad (4.14)$$

Otrzymujemy następujące równania:

$$\begin{cases} \dot{v} = g \sin \alpha - \mu g \cos \alpha - \frac{k_1}{m} v - \frac{k_2}{m} v^2 \\ v = \dot{x} \end{cases} \quad (4.15)$$

Pamiętamy przy tym, że:

$$\begin{cases} k_2 = 0 & v \leq B \\ k_1 = 0 & v \geq B \end{cases} \quad (4.16)$$

Powyższy układ równań wystarczy wykorzystać w dostępnych w wielu językach funkcjach bibliotecznych do rozwiązywania równań różniczkowych zwyczajnych. W naszym przypadku wykorzystaliśmy funkcję `dopri` (Numerical integration of ODE using Dormand-Prince RK method) z biblioteki `Numeric Javascript`.

4.3.1. Rozwiązanie w 3D

Powyższy układ równań opisuje poruszanie się punktu materialnego po równi pochyłej. Jednak w przypadku narciarza przemieszczającego się po stoku musimy uwzględnić również możliwość poruszania się w poprzek stoku, a nie tylko w dół.

Założmy, że narciarz porusza się tylko po liniach prostych.

Rozpatrzmy teraz jak będzie wyglądał układ sił działających na narciarza:

Na naszego narciarza działają siły: grawitacji - w kierunku pionowym oraz siły oporu - w kierunku linii jazdy narciarza. Jeśli rozpatrzmy teraz układ współrzędnych zorientowany względem kierunku jazdy, musimy najpierw zrzutować siłę grawitacji otrzymując siłę ściąającą narciarza:

$$g \sin \alpha * \sinus \quad (4.17)$$

gdzie \sinus to:

Zatem nasze równanie ruchu będzie wyglądało następująco:

$$\ddot{x} = g \sin \alpha * \sinus - \left(\mu F_n + \frac{k_1}{m} \dot{x} + \frac{k_2}{m} \dot{x}^2 \right) \quad (4.18)$$

gdzie F_n to siła nacisku narciarza, która pozostaje taka sama jak w przypadku 2D:

$$F_n = g \cos \alpha \quad (4.19)$$

Transformując powyższe równanie na układ współrzędnych zorientowany wzdłuż i w poprzek stoku otrzymamy następujące równania:

$$\begin{cases} \ddot{x}_x = (g * \sin \alpha * \sinus - (\mu * F_n + \frac{k_1}{m} \dot{x} + \frac{k_2}{m} \dot{x}^2)) * \sinus \\ \ddot{x}_y = (g * \sin \alpha * \sinus - (\mu * F_n + \frac{k_1}{m} \dot{x} + \frac{k_2}{m} \dot{x}^2)) * \cosinus \end{cases} \quad (4.20)$$

Po wprowadzeniu jak poprzednio dodatkowych zmiennych, w tym wypadku prędkości v_x i v_y oraz pamiętaniu o zależności między nimi a pochodną przemieszczenia:

$$\begin{cases} v_x = \dot{x}_x \\ v_y = \dot{x}_y \\ \dot{x} = \sqrt{v_x^2 + v_y^2} \end{cases} \quad (4.21)$$

otrzymujemy:

$$\begin{cases} v_x = \dot{x}_x \\ v_y = \dot{x}_y \\ \dot{v}_x = (g * \sin \alpha * \sinus - (\mu * N + \frac{k_1}{m} \dot{x} + \frac{k_2}{m} \dot{x}^2)) * \sinus \\ \dot{v}_y = (g * \sin \alpha * \sinus - (\mu * N + \frac{k_1}{m} \dot{x} + \frac{k_2}{m} \dot{x}^2)) * \cosinus \end{cases} \quad (4.22)$$

$$\begin{cases} v_x = \dot{x}_x \\ v_y = \dot{x}_y \\ \dot{v}_x = g \sin \alpha - (\dot{x}_x^2 + \dot{x}_y^2)^{\frac{1}{2}} \kappa \dot{x}_y \operatorname{sgn}(\dot{\varphi}) - g \sin \alpha \frac{\dot{x}_y^2}{\dot{x}_x^2 + \dot{x}_y^2} - \frac{(F_f + F_d)}{m} \frac{\dot{x}_x}{(\dot{x}_x^2 + \dot{x}_y^2)^{\frac{1}{2}}} \\ \dot{v}_y = (\dot{x}_x^2 + \dot{x}_y^2)^{\frac{1}{2}} \kappa \dot{x}_x \operatorname{sgn}(\dot{\varphi}) + g \sin \alpha \frac{\dot{x}_x}{\dot{x}_x^2 + \dot{x}_y^2} - \frac{(F_f + F_d)}{m} \frac{\dot{x}_y}{(\dot{x}_x^2 + \dot{x}_y^2)^{\frac{1}{2}}} \end{cases}$$

4.4. Optymalizacja toru przejazdu

4.4.1. Algorytm ewolucyjny

Aby znaleźć rozwiązanie problemu, należy przyjąć jakiś sposób reprezentacji każdego z rozwiązań. Tor przejazdu narciarza w rzeczywistości to ślad, który pozostawiają narty na śniegu w trakcie przemieszczania się po stoku. Jak opisano w rozdziale 4.2, w celu uproszczenia sposobu przemieszczania się narciarza, zostało zdecydowane, że jako przybliżenie można przyjąć poruszanie się po łamanej. Zatem do reprezentacji rozwiązania można przyjąć zbiór punktów, przez które kolejno przejeżdża narciarz, poruszając się między tymi punktami wyłącznie po linii prostej.

Jednak wciąż takie podejście jest zbyt ogólne, ponieważ w algorytmie ewolucyjnym potrzebujemy stałej liczby punktów, aby móc wykonywać np. krzyżowanie dwóch osobników. Zatem w zaproponowanym rozwiązaniu narzucamy z góry co ile metrów w pionie stoku ma pojawić się punkt. Oprócz tego narzucone zostało, że narciarz musi przejechać jak najbliżej wewnętrznej bramki co indukuje dołożenie punktu w miejscu każdej wewnętrznej bramki.

Punkty te, a ściślej, ich położenie w pozycji poziomej jest reprezentacją konkretnego rozwiązania problemu i w ten sposób właśnie określony jest genotyp każdego osobnika. Nie wprowadzamy tu typowego dla algorytmów genetycznych kodowania binarnego, pozycja punktu jest zapamiętana jako wartość rzeczywista.

Zastosowany algorytm opiera się na strategii $(\mu + \lambda)$ opisanej w rozdziale 2

4.5. Architektura systemu

5. Wyniki

W rozdziale tym przedstawiono informacje .

5.1. Optymalizacja

5.1.1. Algorytm ewolucyjny

5.1.2. Lokalna optymalizacja

5.2. Uczenie maszynowe

5.3. Podsumowanie

5.4. Optymalizacja toru przejazdu

5.5. Architektura systemu

6. Podsumowanie

W rozdziale tym przedstawiono informacje .

6.1. Podrozdział

Bibliografia

- [1] A. DILLER, *LaTeX wiersz po wierszu*, Wydawnictwo Helion, Gliwice, 2000.
- [2] L. LAMPORT, *LaTeX system przygotowywania dokumentów*, Wydawnictwo Ariel, Krakow, 1992.
- [3] M. SZPYRKA, *On Line Alvis Manual*, AGH University of Science and Technology, 2011,
<http://fm.ia.agh.edu.pl/alvis:manual>.